Capítulo 7

Sistemas de equações não lineares

7.1 Introdução

Um sistema de equações não lineares tem a forma

$$\begin{cases} f_1(x_1,\ldots,x_n)=0 \\ f_2(x_1,\ldots,x_n)=0 \\ \vdots \\ f_m(x_1,\ldots,x_n)=0, \end{cases} \tag{7.1.1}$$

onde $m,\ n \in \mathbb{N}$ e $f_1,\ f_2,\ldots,\ f_m$ são funções reais de variáveis reais:

$$f_j : \mathbb{R}^n \longmapsto \mathbb{R}, \qquad j \in \{1,\ 2,\ \ldots,\ m\}.$$

O sistema (7.1.1) pode ser escrito na forma vectorial seguinte,

$$\mathbf{F}(\boldsymbol{x}) = \mathbf{0},$$

onde $\mathbf{F} : \mathbb{R}^n \longmapsto \mathbb{R}^m$, $\boldsymbol{x} = (x_1,\ldots,x_n)$ e $\mathbf{0} = (0,\ldots,0)$ tem m componentes, com

$$\mathbf{F}(x_1,\ldots,x_n) = \big(f_1(x_1,\ldots,x_n),\ldots,f_m(x_1,\ldots,x_n)\big),$$

podendo ser também escrito na forma matricial

$$\mathbf{F}(x_1,\ldots,x_n) = \begin{bmatrix} f_1(x_1,\ldots,x_n) \\ \vdots \\ f_m(x_1,\ldots,x_n) \end{bmatrix}$$

Tal como para os sistemas de equações lineares, vamo-nos focar em sistemas de equações não lineares que sejam possíveis determinados. Por isso, vamo-nos cingir ao caso em que o número de equações é igual ao número de incógnitas, ou seja

$$m = n.$$

Exemplo 7.1.1. Consideremos o sistema de equações não lineares

$$\begin{cases} 3x_1 - \cos(x_2 x_3) = \frac{1}{2} \\ x_1^2 - 81(x_2 + 0.1)^2 + \operatorname{sen}(x_3) = -1.06 \\ \vdots \\ e^{-x_1 x_2} + 20x_3 = 1 - \frac{10}{3}\pi, \end{cases}$$

o qual se pode escrever na forma

$$\begin{cases} f_1(x_1, x_2, x_3) = 0 \\ f_2(x_1, x_2, x_3) = 0 \\ f_3(x_1, x_2, x_3) = 0, \end{cases}$$

com

$$\begin{cases} f_1(x_1, x_2, x_3) = 3x_1 - \cos(x_2 x_3) - \frac{1}{2} \\ f_2(x_1, x_2, x_3) = x_1^2 - 81(x_2 + 0.1)^2 + \operatorname{sen}(x_3) + 1.06 \\ f_3(x_1, x_2, x_3) = e^{-x_1 x_2} + 20x_3 - 1 + \frac{10}{3}\pi, \end{cases}$$

ou, ainda, na forma matricial

$$\mathbf{F}(\boldsymbol{x}) = \mathbf{0} \Leftrightarrow \begin{bmatrix} f_1(x_1, x_2, x_3) \\ f_2(x_1, x_2, x_3) \\ f_3(x_1, x_2, x_3) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

Na definição seguinte apresentamos a noção de limite de uma função real de várias variáveis reais.

Definição 7.1.1. Seja $f : \mathbb{D} \subset \mathbb{R}^n \longmapsto \mathbb{R}$ uma função real de n variáveis reais. Dizemos que $L \in \mathbb{R}$ é o **limite** de f num ponto $\boldsymbol{a} = (a_1, \ldots, a_n) \in \mathbb{D}$, e escrevemos

$$\forall\, \varepsilon > 0\ \exists\, \delta > 0 : \forall\, (x_1, \ldots, x_n) \in \mathbb{D}\ \|(x_1, \ldots, x_n) - (a_1, \ldots, a_n)\| < \delta \Rightarrow |f(x_1, \ldots, x_n) - L| < \varepsilon\,.$$

Com a ajuda da definição anterior, definimos a noção de continuidade para uma função real de várias variáveis reais.

Definição 7.1.2. Seja $f : \mathbb{D} \subset \mathbb{R}^n \longmapsto \mathbb{R}$ uma função real de n variáveis reais. Dizemos que f é contínua num ponto $\boldsymbol{a} = (a_1, \ldots, a_n) \in \mathbb{D}$, se o limite seguinte existir,

$$\lim_{\boldsymbol{x} \to \boldsymbol{a}} f(\boldsymbol{x}),$$

e se tivermos

$$\lim_{\boldsymbol{x} \to \boldsymbol{a}} f(\boldsymbol{x}) = f(\boldsymbol{a}).$$

No caso de uma função vectorial, a noção de continuidade da definição anterior estende-se como indicado a seguir.

Definição 7.1.3. Seja $\mathbf{F} : \mathbb{D} \subset \mathbb{R}^n \longmapsto \mathbb{R}^m$ uma função vectorial de n variáveis reais, e suponhamos que $\mathbf{F}$ tem a representação seguinte,

$$\mathbf{F}(\boldsymbol{x}) = (f_1(\boldsymbol{x}), \ldots, f_m(\boldsymbol{x})), \qquad \boldsymbol{x} = (x_1, \ldots, x_n) \in \mathbb{D}.$$

Dizemos que $\mathbf{F}$ é contínua num ponto $\boldsymbol{a} = (a_1, \ldots, a_n) \in \mathbb{D}$, se os limites seguintes existirem,

$$\lim_{\boldsymbol{x} \to \boldsymbol{a}} f_j(\boldsymbol{x}), \quad j \in \{1, \ldots, m\},$$

e se tivermos

$$\lim_{\boldsymbol{x} \to \boldsymbol{a}} f_j(\boldsymbol{x}) = f_j(\boldsymbol{a}), \quad j \in \{1, \ldots, m\}.$$

Na proposição seguinte apresentamos uma condição suficiente de continuidade para uma função vectorial.

Proposição 7.1.1. Seja $f : \mathbb{D} \subset \mathbb{R}^n \longmapsto \mathbb{R}$ uma função real de n variáveis reais e seja $\boldsymbol{a} = (a_1, \ldots, a_n) \in \mathbb{D}$. Se existirem constantes $\delta > 0$ e $K >$ tais que

$$\left| \frac{\partial f(\boldsymbol{x})}{\partial x_i} \right| \leq K \quad \forall\, i \in \{1, \ldots, n\},$$

sempre que $\boldsymbol{x} \in \mathbb{D}$ e $\|\boldsymbol{x} - \boldsymbol{a}\| < \delta$, então f é contínua em $\boldsymbol{x} = \boldsymbol{a}$.

Nos métodos numéricos que iremos explorar nesta secção é muito importante a noção de ponto fixo, que apresentamos a seguir.

Definição 7.1.4. Seja $\mathbf{G} : \mathbb{D} \subset \mathbb{R}^n \longmapsto \mathbb{R}^n$ uma função vectorial de n variáveis reais. Dizemos que $\mathbf{G}$ tem um ponto fixo em $\boldsymbol{x} = \boldsymbol{a}$ se

$$\mathbf{G}(\boldsymbol{a}) = \boldsymbol{a},$$

ou seja se

$$\begin{cases} g_1(a_1, \ldots, a_n) = a_1 \\ \vdots \\ g_n(a_1, \ldots, a_n) = a_n\,. \end{cases}$$

A proposição seguinte é conhecida na literatura por Teorema da Contracção, o qual na verdade é um caso particular do Teorema do Ponto Fixo de Banach.

Proposição 7.1.2. Sejam $\mathbb{D} = [a_1, b_1] \times \cdots \times [a_n, b_n] \subset \mathbb{R}^n$, com $a_1,\ b_1,\ \ldots,\ a_n,\ b_n \in \mathbb{R}$, e $\mathbf{G} : \mathbb{D} \longrightarrow \mathbb{R}^n$ uma função contínua com a propriedade de que

$$\mathbf{G}(\boldsymbol{x}) \in \mathbb{D} \quad \forall\, \boldsymbol{x} \in \mathbb{D}.$$

 © HBO, 2025/2026

Admitamos que $\mathbf{G}$ tem a representação $\mathbf{G} = (g_1, \ldots, g_n)$ e suponhamos que

$$\exists\, K \in (0,1) : \left|\frac{\partial g_i(\boldsymbol{x})}{\partial x_i}\right| \leq \frac{K}{n} \quad \forall\, i \in \{1, \ldots, n\}.$$

Então a sucessão $\boldsymbol{x}_k$ definida, para um valor arbitrário $\boldsymbol{x}^0$, por

$$\boldsymbol{x}^k = \mathbf{G}(\boldsymbol{x}^{k-1}), \quad k \geq 1,$$

converge para o único ponto fixo $\boldsymbol{x}^* \in \mathbb{D}$, e, ainda,

$$\|\boldsymbol{x}^k - \boldsymbol{x}^*\|_\infty < \frac{K^n}{1-K}\|\boldsymbol{x}^1 - \boldsymbol{x}^0\|_\infty.$$

7.2 Aplicação dos métodos de Jacobi e Gauss-Seidel

Aquando do estudo de sistemas de equações lineares, já vimos os métodos de Jacobi e de Gauss-Seidel. Vamos ver nesta secção como se podem aplicar estes métodos na resolução de sistemas de equações não lineares. Para percebermos melhor, vejamos o exemplo seguinte.

Consideremos o sistema de equações não lineares do Exemplo 7.1.1, o qual escrevemos na forma seguinte

$$\begin{cases} 3x_1 - \cos(x_2 x_3) - \frac{1}{2} \\ x_1^2 - 81(x_2 + 0.1)^2 + \operatorname{sen}(x_3) + 1.06 \\ e^{-x_1 x_2} + 20x_3 - 1 + \frac{10}{3}\pi\,. \end{cases}$$

Isolando, em cada equação, a variável com o mesmo índice da posição da equação, obtemos

$$\begin{cases} x_1 = \frac{1}{3}\cos(x_2 x_3) + \frac{1}{2} + \frac{1}{6} \\ x_2 = \frac{1}{9}\sqrt{x_1^2 + \operatorname{sen}(x_3) + 1.06} - 0.1 \\ x_3 = -\frac{1}{20}e^{-x_1 x_2} + \frac{1}{20} - \frac{\pi}{6}\,. \end{cases}$$

Definamos uma função vectorial $\mathbf{G} = (g_1, g_2, g_3)$ por

$$\begin{aligned} g_1(x_1, x_2, x_3) &= \tfrac{1}{3}\cos(x_2 x_3) + \tfrac{1}{2} + \tfrac{1}{6} \\ g_2(x_1, x_2, x_3) &= \tfrac{1}{9}\sqrt{x_1^2 + \operatorname{sen}(x_3) + 1.06} - 0.1 \\ g_3(x_1, x_2, x_3) &= -\tfrac{1}{20}e^{-x_1 x_2} + \tfrac{1}{20} - \tfrac{\pi}{6}\,. \end{aligned}$$

Consideremos o cubo $\mathbb{D} = [-1,1] \times [-1,1] \times [-1,1]$. Podemos mostrar que para $(x_1, x_2, x_3) \in \mathbb{D}$ se tem

$$\begin{aligned} |g_1(x_1, x_2, x_3)| &\leq 0.5 \\ |g_2(x_1, x_2, x_3)| &\leq 0.3 \\ |g_3(x_1, x_2, x_3)| &\leq 0.8\,, \end{aligned}$$

pelo que $\mathbf{G}(x_1, x_2, x_3) \in \mathbb{D}$ para todo $(x_1, x_2, x_3) \in \mathbb{D}$.

Por outro lado, temos para todo $(x_1, x_2, x_3) \in \mathbb{D}$

$$\left|\frac{\partial g_i}{\partial x_i}\right| = 0, \quad i \in \{1, 2, 3\}$$

$$\left|\frac{\partial g_1}{\partial x_2}\right| < 0.281, \quad \left|\frac{\partial g_1}{\partial x_3}\right| < 0.281,$$
$$\left|\frac{\partial g_2}{\partial x_1}\right| < 0.238, \quad \left|\frac{\partial g_2}{\partial x_3}\right| < 0.119,$$
$$\left|\frac{\partial g_3}{\partial x_1}\right| < 0.14, \quad \left|\frac{\partial g_3}{\partial x_2}\right| < 0.019.$$

Como as derivadas parciais $\frac{\partial g_i}{\partial x_j}$, com $i, j \in \{1, 2, 3\}$, são limitadas no cubo $\mathbb{D}$, então $\mathbf{G}(x_1, x_2, x_3) = \big(g_1(x_1, x_2, x_3), g_2(x_1, x_2, x_3), g_3(x_1, x_2, x_3)\big)$ é contínua em $\mathbb{D}$. E pelo exposto acima, temos

$$\left|\frac{\partial g_i}{\partial x_j}\right| \leq \max\{0.281, 0.238, 0.119, 0.14, 0.019\} = 0.238.$$

Logo, o Teorema da Contracção é satisfeito com

$$\frac{K}{n} = 0.281 \Leftrightarrow \frac{K}{3} = 0.281 \Leftrightarrow K = 0.843,$$

pelo que a função vectorial $\mathbb{G}$ vai ter um ponto fixo $\boldsymbol{x}^*$ no cubo $\mathbb{D}$. Então o sistema de equações não lineares dado vai ter uma solução em $\mathbb{D}$, a qual vai ser gerada pelo sistema seguinte

$$\begin{cases} x_1^k = \frac{1}{3}\cos(x_2^{k-1}x_3^{k-1}) + \frac{1}{2} + \frac{1}{6} \\ x_2^k = \frac{1}{9}\sqrt{(x_1^{k-1})^2 + \operatorname{sen}(x_3^{k-1}) + 1.06} - 0.1 \\ x_3^k = -\frac{1}{20}e^{-x_1^{k-1}x_2^{k-1}} + \frac{1}{20} - \frac{\pi}{6}\,. \end{cases}$$

Resolvendo até à iteração $\boldsymbol{x}^k = (x_1^k, x_2^k, x_3^k)$ satisfazer a tolerância

$$\|\boldsymbol{x}^k - \boldsymbol{x}^{k-1}\|_\infty = \|(x_1^k, x_2^k, x_3^k) - (x_1^{k-1}, x_2^{k-1}, x_3^{k-1})\|_\infty < 10^{-5},$$

obtemos os valores da tabela seguinte

k	x_1^k	x_2^k	x_3^k	$\|\boldsymbol{x}^k - \boldsymbol{x}^{k-1}\|_\infty$
0	0.10000000	0.10000000	−0.10000000	
1	0.49998333	0.00944115	−0.52310127	0.423
2	0.49999593	0.00002557	−0.52336331	9.4×10^{-3}
3	0.50000000	0.00001234	−0.52359814	2.3×10^{-4}
4	0.50000000	0.00000003	−0.52359847	1.2×10^{-5}
5	0.50000000	0.00000002	−0.52359877	3.1×10^{-7}

Estimando o erro cometido na iteração de paragem, em relação ao ponto fixo $\boldsymbol{x}^*$ temos

$$\|\boldsymbol{x}^5 - \boldsymbol{x}^*\|_\infty < \frac{K^n}{1-K}\|\boldsymbol{x}^1 - \boldsymbol{x}^0\|_\infty = \frac{0.843^3}{1-0.843} \times 0.423 < 1.15.$$

No entanto, o valor obtido não nos dá a verdadeira precisão da iteração $\boldsymbol{x}^5$. Isto deve-se essencialmente ao valor da iteração inicial $\boldsymbol{x}^0$ considerado.

Para acelerar a convergência deste método, podemos proceder como para o Método de Gauss-Seidel para sistemas de equações lineares, actualizando, sempre que possível, a informação das componentes

já conhecidas na mesma iteração:

$$\begin{cases} x_1^k = \frac{1}{3}\cos(x_2^{k-1}x_3^{k-1}) + \frac{1}{2} + \frac{1}{6} \\ x_2^k = \frac{1}{9}\sqrt{(x_1^k)^2 + \operatorname{sen}(x_3^{k-1}) + 1.06} - 0.1 \\ x_3^k = -\frac{1}{20}e^{-x_1^k x_2^k} + \frac{1}{20} - \frac{\pi}{6}\,. \end{cases}$$

Usando este método, com os mesmos valores para a iteração inicial e para a tolerância absoluta que usámos na tabela anterior, obtemos os valores da tabela seguinte:

k	x_1^k	x_2^k	x_3^k	$\|\boldsymbol{x}^k - \boldsymbol{x}^{k-1}\|_\infty$
0	0.10000000	0.10000000	−0.10000000	
1	0.49998333	0.00944115	−0.52310127	0.423
2	0.49997747	0.00002815	−0.52359807	2.2×10^{-2}
3	0.50000000	0.00000004	−0.52359877	2.8×10^{-5}
4	0.50000000	0.00000000	−0.52359877	3.8×10^{-8}

Neste caso, o método parou na iteração $\boldsymbol{x}^4$, o que melhorou o método anterior. Note-se que também seria $\boldsymbol{x}^4$ a iteração de paragem se tivéssemos escolhido a tolerância absoluta inferior a 10^{-7}.

Os Métodos de Jacobi e Gauss-Seidel podem ser transformados em métodos de ponto fixo com a seguinte forma

$$\begin{cases} x_1 = g_1(x_1, x_2 \ldots, x_n) \\ x_2 = g_2(x_1, x_2 \ldots, x_n) \\ \vdots \\ x_n = g_n(x_1, x_2 \ldots, x_n)\,. \end{cases}$$

Por exemplo, o sistema de equações não lineares

$$\begin{cases} 4x_1^2 - 20x_1 + \frac{1}{4}x_2^2 + 8 = 0 \\ \frac{1}{2}x_2x_2^2 + 2x_1 - 5x_2 + 8 = 0 \end{cases}$$

pode ser transformado no problema de ponto fixo seguinte,

$$\begin{cases} x_1 = \frac{1}{5}x_1^2 + \frac{1}{80}x_2^2 + \frac{2}{5} \\ x_2 = \frac{1}{10}x_1x_2^2 + x_1 + 4. \end{cases}$$

Deste modo, podemos implementar o Método de Jacobi

$$\begin{cases} x_1^k = \frac{1}{5}(x_1^{k-1})^2 + \frac{1}{80}(x_2^{k-1})^2 + \frac{2}{5} \\ x_2^k = \frac{1}{10}x_1^{k-1}(x_2^{k-1})^2 + x_1^{k-1} + 4, \end{cases} \tag{7.2.2}$$

bem como o Método de Gauss-Seidel

$$\begin{cases} x_1^k = \frac{1}{5}(x_1^{k-1})^2 + \frac{1}{80}(x_2^{k-1})^2 + \frac{2}{5} \\ x_2^k = \frac{1}{10}x_1^{k}(x_2^{k-1})^2 + x_1^{k} + 4, \end{cases} \tag{7.2.3}$$

Para os distinguir dos métodos de Jacobi e de Gauss-Seidel, tal como foram usados para aproximar soluções de sistemas de equações lineares, vamos designar o método usado em (7.2.2) por **Método de Jacobi Funcional** e o usado em (7.2.3) por **Método de Gauss-Seidel Funcional**.

7.3 Método de Newton

Recordemos que o Método de Newton, quando aplicado a uma só equação não linear, consistiu em encontrar uma função $\phi(x)$ com a propriedade de que

$$g(x) = x - \phi(x)f(x)$$

dava uma convergência de 2ª ordem para o ponto fixo da função $g(x)$. Para esta condição ser satisfeita, vimos que a escolha

$$\phi(x) = \frac{1}{f'(x)}$$

era adequada.

Usando uma abordagem similar, no caso de um sistema de equações não lineares, escrito na forma

$$\begin{cases} f_1(\boldsymbol{x}) = 0 \\ f_2(\boldsymbol{x}) = 0 \\ \vdots \\ f_n(\boldsymbol{x}) = 0, \end{cases}$$

vamos considerar a matriz

$$A(\boldsymbol{x}) = \begin{bmatrix} a_{11}(\boldsymbol{x}) & a_{12}(\boldsymbol{x}) & \cdots & a_{1n}(\boldsymbol{x}) \\ a_{21}(\boldsymbol{x}) & a_{22}(\boldsymbol{x}) & \cdots & a_{2n}(\boldsymbol{x}) \\ \cdots & \vdots & \ddots & \vdots \\ a_{n1}(\boldsymbol{x}) & a_{n2}(\boldsymbol{x}) & \cdots & a_{nn}(\boldsymbol{x}), \end{bmatrix}$$

onde cada uma das entradas a_{ij} da matriz A é uma função real de n variáveis reais:

$$a_{ij} : \mathbb{R}^n \longrightarrow \mathbb{R}, \qquad i,\ j \in \{1, \ldots, n\}.$$

A matriz A a determinar deve ser tal que a equação vectorial, assumindo que a matriz A não é singular ($\det(A) \neq 0$),

$$G(\boldsymbol{x}) = \boldsymbol{x} - A(\boldsymbol{x})^{-1}F(\boldsymbol{x}), \qquad F(\boldsymbol{x}) = \begin{bmatrix} f_1(\boldsymbol{x}) \\ f_2(\boldsymbol{x}) \\ \vdots \\ f_n(\boldsymbol{x}), \end{bmatrix}$$

fornece uma convergência quadrática para a solução do sistema de equações não lineares, representado na forma vectorial por

$$F(\boldsymbol{x}) = \mathbf{0}.$$

Proposição 7.3.1. Seja $\boldsymbol{x}^*$ uma solução da equação vectorial

$$G(\boldsymbol{x}) = \boldsymbol{x},$$

para alguma função $G : \mathbb{R}^n \longrightarrow \mathbb{R}^n$. Se existir uma constante $\delta > 0$ tal que:

(1) $\dfrac{\partial g_i}{\partial x_j}$ é contínua em $\Omega_\delta = \{\boldsymbol{x} \in \mathbb{R}^n : \|\boldsymbol{x} - \boldsymbol{x}^*\| < \delta\}$ para todos $i,\ j \in \{1, \ldots, n\}$;

(2) $\dfrac{\partial^2 g_i}{\partial x_j x_k}$ é contínua e $\left|\dfrac{\partial^2 g_i}{\partial x_j x_k}\right| \leq M$ em Ω_δ, para alguma constante positiva M, e para todos $i,\ j,\ k \in \{1,\ldots,n\}$;

(3) $\dfrac{\partial g_i(\boldsymbol{x}^*)}{\partial x_j} = 0$ para todos $i,\ j \in \{1,\ldots,n\}$;

então existe outra constante $\overline{\delta} : 0 < \overline{\delta} < \delta$ tal que a sucessão gerada por

$$\boldsymbol{x}^k = G(\boldsymbol{x}^{k-1})$$

converge quadraticamente para $\boldsymbol{x}^*$, para qualquer escolha da iteração inicial $\boldsymbol{x}^0$, mas desde que

$$\|\boldsymbol{x}^0 - \boldsymbol{x}^*\| < \overline{\delta}.$$

Mais ainda,

$$\|\boldsymbol{x}^k - \boldsymbol{x}^*\|_\infty \leq \frac{n^2 M}{2}\|\boldsymbol{x}^{k-1} - \boldsymbol{x}^*\|_\infty^2 < \delta \quad \forall\ k \geq 1.$$

Para aplicar a proposição anterior, suponhamos que

$$A(\boldsymbol{x})^{-1} = B(\boldsymbol{x}).$$

Como

$$G(\boldsymbol{x}) = \boldsymbol{x} - A(\boldsymbol{x})^{-1}F(\boldsymbol{x}) = \boldsymbol{x} - B(\boldsymbol{x})F(\boldsymbol{x}),$$

temos

$$g_i(\boldsymbol{x}) = x_i - \sum_{j=1}^{n} b_{ij}(\boldsymbol{x}) f_j(\boldsymbol{x}), \quad i \in \{1,\ldots,n\}.$$

Assim,

$$\frac{\partial g_i(\boldsymbol{x})}{\partial x_k} = 1 - \sum_{j=1}^{n}\left(\frac{\partial b_{ij}(\boldsymbol{x})}{\partial x_k} f_j(\boldsymbol{x}) + b_{ij}(\boldsymbol{x})\frac{\partial f_j(\boldsymbol{x})}{\partial x_k}\right), \quad k = i,$$

$$\frac{\partial g_i(\boldsymbol{x})}{\partial x_k} = -\sum_{j=1}^{n}\left(\frac{\partial b_{ij}(\boldsymbol{x})}{\partial x_k} f_j(\boldsymbol{x}) + b_{ij}(\boldsymbol{x})\frac{\partial f_j(\boldsymbol{x})}{\partial x_k}\right), \quad k \neq i.$$

A proposição anterior obriga a que

$$\frac{\partial g_i(\boldsymbol{x}^*)}{\partial x_k} = 0 \quad \forall\ i,\ k \in \{1,\ldots,n\}.$$

Então em $\boldsymbol{x} = \boldsymbol{x}^*$, temos

$$0 = 1 - \sum_{j=1}^{n} b_{ij}(\boldsymbol{x}^*)\frac{\partial f_j(\boldsymbol{x}^*)}{\partial x_k}, \quad k = i,$$

$$0 = -\sum_{j=1}^{n} b_{ij}(\boldsymbol{x}^*)\frac{\partial f_j(\boldsymbol{x}^*)}{\partial x_k}, \quad k \neq i,$$

o que equivale a

$$\sum_{j=1}^{n} b_{ij}(\boldsymbol{x}^*)\frac{\partial f_j(\boldsymbol{x}^*)}{\partial x_k} = 1, \quad k = i,$$
$$\sum_{j=1}^{n} b_{ij}(\boldsymbol{x}^*)\frac{\partial f_j(\boldsymbol{x}^*)}{\partial x_k} = 0, \quad k \neq i.$$

Definimos, agora, a matriz

$$J(\boldsymbol{x}) = \begin{bmatrix} \frac{\partial f_1(\boldsymbol{x})}{\partial x_1} & \frac{\partial f_1(\boldsymbol{x})}{\partial x_2} & \cdots & \frac{\partial f_1(\boldsymbol{x})}{\partial x_n} \\ \frac{\partial f_2(\boldsymbol{x})}{\partial x_1} & \frac{\partial f_2(\boldsymbol{x})}{\partial x_2} & \cdots & \frac{\partial f_2(\boldsymbol{x})}{\partial x_n} \\ \cdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n(\boldsymbol{x})}{\partial x_1} & \frac{\partial f_n(\boldsymbol{x})}{\partial x_2} & \cdots & \frac{\partial f_n(\boldsymbol{x})}{\partial x_n} \end{bmatrix}.$$

As igualdades anteriores podem então ser escritas na forma matricial seguinte

$$A(\boldsymbol{x}^*)^{-1}J(\boldsymbol{x}^*) = I_n \Leftrightarrow A(\boldsymbol{x}^*) = J(\boldsymbol{x}^*),$$

onde I_n denota a matriz unitária de ordem n.

Deste modo, podemos então escrever

$$G(\boldsymbol{x}) = \boldsymbol{x} - J(\boldsymbol{x})^{-1}F(\boldsymbol{x})$$

e, assim, construir um método iterativo

$$\boldsymbol{x}^k = \boldsymbol{x}^{k-1} - J(\boldsymbol{x}^{k-1})^{-1}F(\boldsymbol{x}^{k-1}), \quad k \geq 1, \tag{7.3.4}$$

onde a iteração inicial $\boldsymbol{x}^0$ pode ser escolhida arbitrariamente.

A equação (7.3.4) dá-nos uma **fórmula iteradora do Método de Newton para sistemas de equações não lineares**.

Exemplo 7.3.1. Consideremos o sistema de equações não lineares dado no Exemplo 7.1.1, o qual escrevemos na forma

$$\begin{cases} 3x_1 - \cos(x_2x_3) - \frac{1}{2} = 0 \\ x_1^2 - 81(x_2 + 0.1)^2 + \operatorname{sen}(x_3) + 1.06 = 0 \\ \vdots \\ e^{-x_1x_2} + 20x_3 - 1 + \frac{10}{3}\pi = 0 \end{cases}$$

Denotando

$$f_1(x_1, x_2, x_3) = 3x_1 - \cos(x_2x_3) - \frac{1}{2}$$
$$f_2(x_1, x_2, x_3) = x_1^2 - 81(x_2 + 0.1)^2 + \operatorname{sen}(x_3) + 1.06$$
$$f_3(x_1, x_2, x_3) = e^{-x_1x_2} + 20x_3 - 1 + \frac{10}{3}\pi,$$

a matriz Jacobiana do sistema é

$$J(x_1,x_2,x_3)=\begin{bmatrix} 3 & x_3\,\mathrm{sen}(x_2x_3) & x_2\,\mathrm{sen}(x_2x_3) \\ 2x_1 & -162(x_2+0.1) & \cos(x_3) \\ -x_2e^{-x_1x_2} & -x_1e^{-x_1x_2} & 20 \end{bmatrix}.$$

Pela fórmula iteradora do Método de Newton, temos

$$\boldsymbol{x}^k=\boldsymbol{x}^{k-1}-J(\boldsymbol{x}^{k-1})^{-1}F(\boldsymbol{x}^{k-1}) \Leftrightarrow$$

$$\begin{bmatrix} x_1^k \\ x_2^k \\ x_3^k \end{bmatrix}=\begin{bmatrix} x_1^{k-1} \\ x_2^{k-1} \\ x_3^{k-1} \end{bmatrix}-\begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \frac{\partial f_1}{\partial x_3} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \frac{\partial f_2}{\partial x_3} \\ \frac{\partial f_3}{\partial x_1} & \frac{\partial f_3}{\partial x_2} & \frac{\partial f_3}{\partial x_3} \end{bmatrix}^{-1}_{\boldsymbol{x}=\boldsymbol{x}^{k-1}}\begin{bmatrix} f_1 \\ f_2 \\ f_3 \end{bmatrix}_{\boldsymbol{x}=\boldsymbol{x}^{k-1}} \Leftrightarrow$$

$$\begin{bmatrix} x_1^k \\ x_2^k \\ x_3^k \end{bmatrix}=\begin{bmatrix} x_1^{k-1} \\ x_2^{k-1} \\ x_3^{k-1} \end{bmatrix}-\begin{bmatrix} 3 & x_3^{k-1}\,\mathrm{sen}(x_2^{k-1}x_3^{k-1}) & x_2\,\mathrm{sen}(x_2^{k-1}x_3^{k-1}) \\ 2x_1^{k-1} & -162(x_2^{k-1}+0.1) & \cos(x_3^{k-1}) \\ -x_2^{k-1}e^{-x_1^{k-1}x_2^{k-1}} & -x_1^{k-1}e^{-x_1^{k-1}x_2^{k-1}} & 20 \end{bmatrix}^{-1}\times$$

$$\begin{bmatrix} 3x_1^{k-1}-\cos(x_2^{k-1}x_3^{k-1})-\frac{1}{2} \\ (x_1^{k-1})^2-81(x_2^{k-1}+0.1)^2+\mathrm{sen}(x_3^{k-1})+1.06 \\ e^{-x_1^{k-1}x_2^{k-1}}+20x_3^{k-1}-1+\frac{10}{3}\pi \end{bmatrix}$$

Na tabela seguinte apresentamos as aproximações que resultam de aplicar este método para o mesmo número de iterações dos exemplos anteriores:

k	x_1^k	x_2^k	x_3^k	$\|\boldsymbol{x}^k-\boldsymbol{x}^{k-1}\|_\infty$
0	0.1000000000	0.1000000000	−0.1000000000	
1	0.4998696728	0.0194668485	−0.5215204718	0.4215204718
2	0.5000142403	0.0015885914	−0.5235569638	1.788×10^{-2}
3	0.5000000113	0.0000124448	−0.5235984500	1.576×10^{-3}
4	0.5000000000	8.516×10^{-10}	−0.5235987755	1.244×10^{-5}
5	0.5000000000	-1.375×10^{-11}	−0.5235987756	8.654×10^{-10}

Observação. Como mostra o exemplo anterior, o Método de Newton converge muito rapidamente para a solução exacta $\boldsymbol{x}^*$, desde que seja escolhida uma aproximação inicial $\boldsymbol{x}^0$ que esteja relativamente próxima da solução exacta.

Uma das vantagens do método de Newton é que não tem uma forma complicada para calcular as iterações. Além disso, pode ser usado para resolver uma grande variedade de sistemas de equações. Uma desvantagem associada com o método de Newton, é que a matriz Jacobiana $J(\boldsymbol{x})$, bem como a sua inversa $J(\boldsymbol{x})^{-1}$, devem ser calculadas em cada iteração. Por outro lado, calcular a matriz Jacobiana $J(\boldsymbol{x})$ e a sua inversa $J(\boldsymbol{x})^{-1}$ pode demorar muito tempo, dependendo do número de equações do sistema. É nesta parte que o cálculo numérico, quer seja da matriz Jacobiana ou da sua inversa, nos permite poupar muito tempo. O grande problema do Método de Newton para sistemas de equações não lineares, é que nem sempre é fácil determinar bons valores iniciais. Existem técnicas para encontrar bons valores da iteração inicial, mas não serão abordadas neste curso. Por isso, a iteração inicial será sempre apresentada, e de modo a que o método convirja.

Implementação numérica

(i) Input

- número n de equações = número de incógnitas
- aproximação inicial: $\boldsymbol{x}^0 = (x_1^0, \ldots, x_n^0)$
- tolerância (absoluta ou relativa) na norma $\|\cdot\|_\infty$: TOL
- número máximo de iterações: N_0

(ii) Solução aproximada ou mensagem de erro

1. Set $k = 1$
2. While $k \leq N_0$ do Steps 3-7
   3. Calculate $F(\boldsymbol{x})$ and $J(\boldsymbol{x}) = \left[\frac{\partial f_i}{\partial x_j}\right]_{i,j=1}^{n}$
   4. Solve the $n \times n$ linear system $J(\boldsymbol{x})\boldsymbol{y} = -F(\boldsymbol{x})$
   5. Set $\boldsymbol{x} = \boldsymbol{x} + \boldsymbol{y}$
   6. If $\|\boldsymbol{y}\| < TOL$ then OUTPUT $\boldsymbol{x}$ (Procedimento concluído com sucesso: STOP)
   7. Set $k = k + 1$
8. Output "O Método falhou após N_0 iterações"(Procedimento concluído sem sucesso: STOP)