

Bases de Dados

BIG DATA E NOSQL

©José Barateiro 2024
Adaptado de Silberschatz, Korth e Sudarschan

What is Big Data?



"When you two have finished arguing your opinions, I actually have data!"

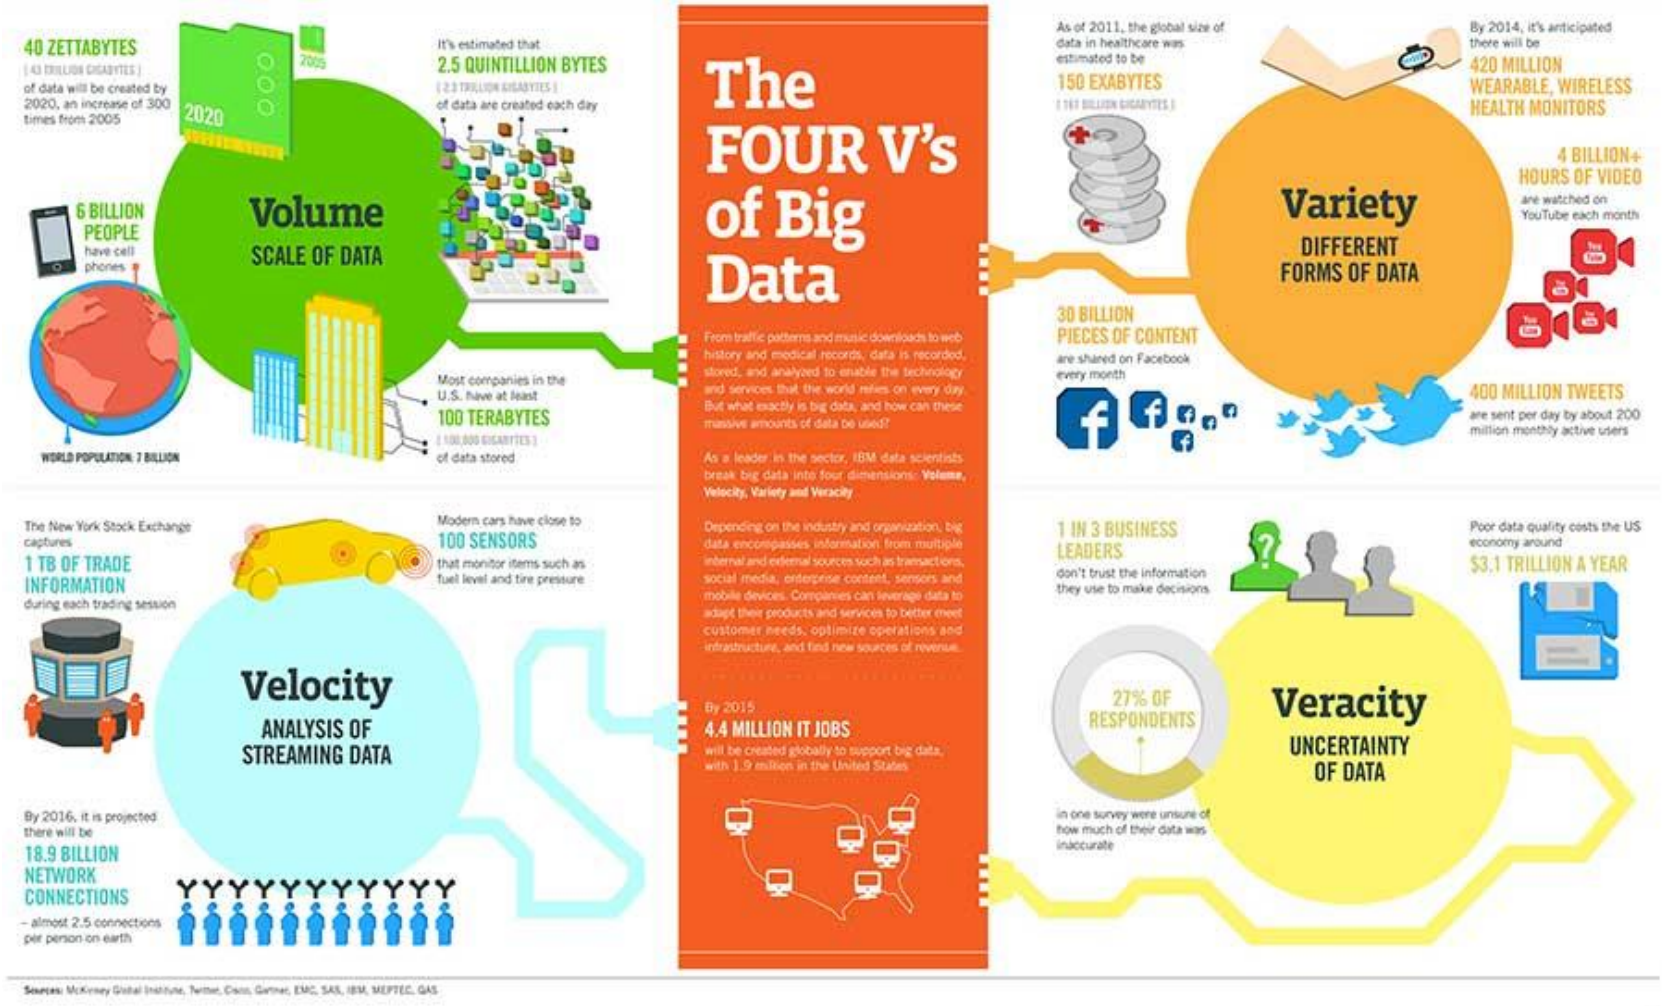
Motivação

- Grandes volumes de dados
  - Impulsionado pelo crescimento da web, redes sociais, IoT, etc.
  - Os weblogs foram uma fonte inicial de dados
    - A análise em web logs tem grande valor para anúncios, estruturação de sites, etc.

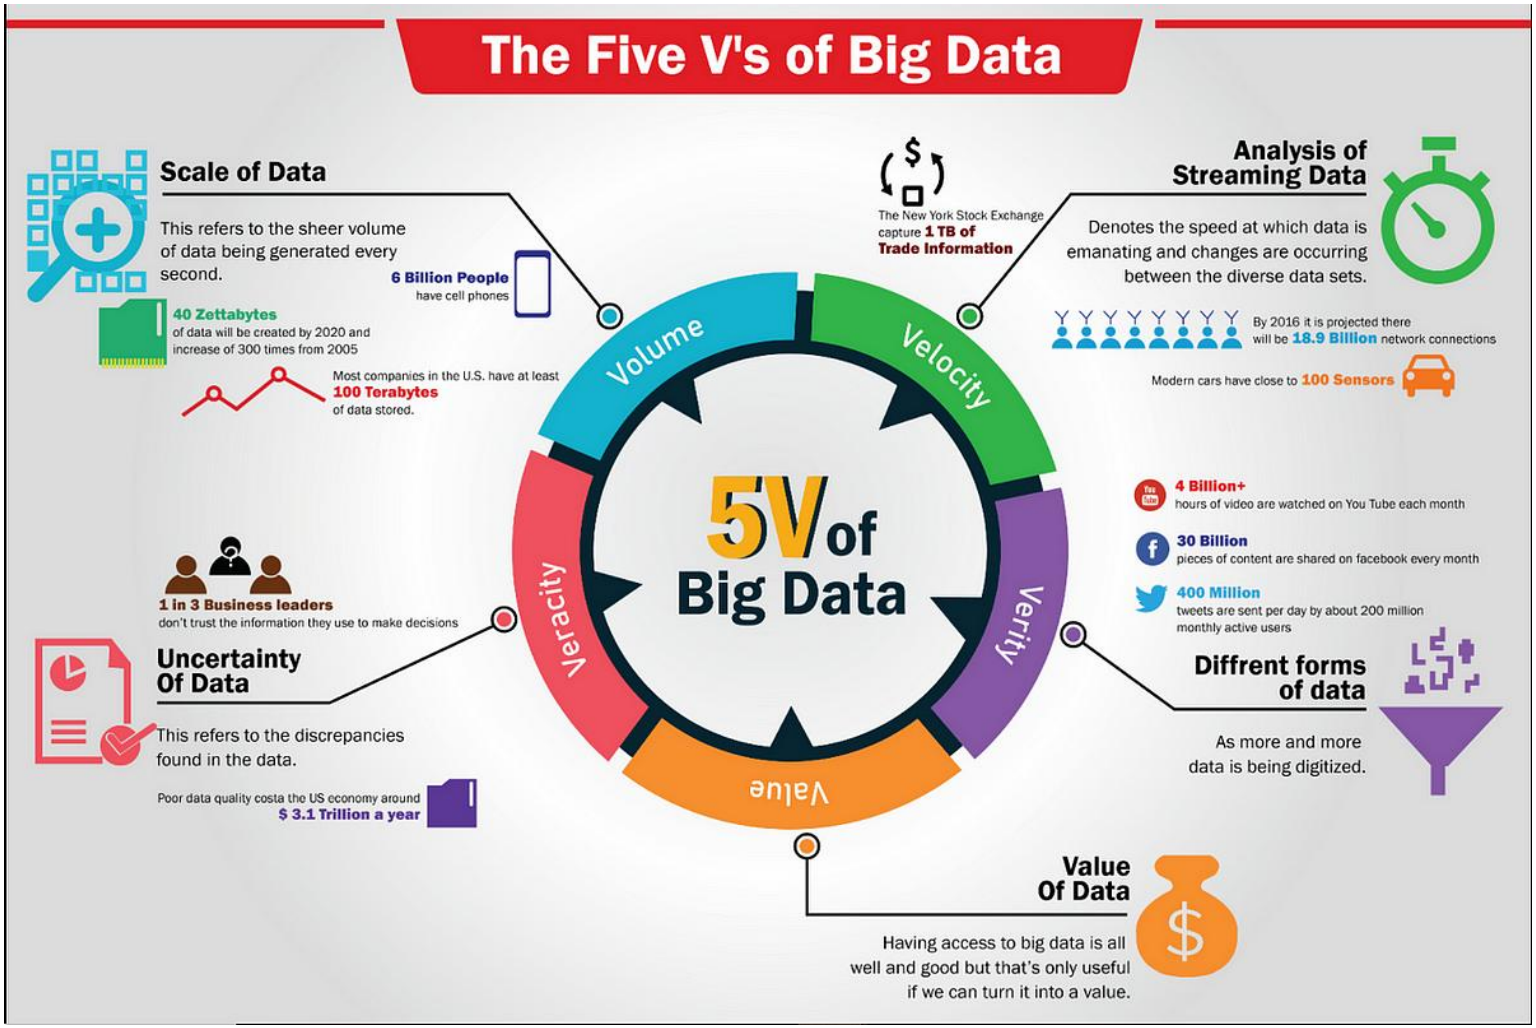
Big Data:

- **Volume** : quantidades muito maiores de dados armazenados
- **Velocidade** : taxas de inserções muito mais altas
- **Variedade** : muitos tipos de dados, além de dados relacionais

Big Data 4V


40 ZETTABYTES
[43 TRILLION GIGABYTES]
of data will be created by 2020, an increase of 300 times from 2005
2005
2020
It's estimated that
2.5 QUINTILLION BYTES
[2.3 TRILLION GIGABYTES]
of data are created each day
6 BILLION PEOPLE
have cell phones
WORLD POPULATION: 7 BILLION
Volume
SCALE OF DATA
Most companies in the U.S. have at least
100 TERABYTES
[100,000 GIGABYTES]
of data stored
The New York Stock Exchange captures
1 TB OF TRADE INFORMATION
during each trading session
Modern cars have close to
100 SENSORS
that monitor items such as fuel level and tire pressure
Velocity
ANALYSIS OF STREAMING DATA
By 2016, it is projected there will be
18.9 BILLION NETWORK CONNECTIONS
– almost 2.5 connections per person on earth
The FOUR V's of Big Data
From traffic patterns and music downloads to web history and medical records, data is recorded, stored, and analyzed to enable the technology and services that the world relies on every day. But what exactly is big data, and how can these massive amounts of data be used?
As a leader in the sector, IBM data scientists break big data into four dimensions: Volume, Velocity, Variety and Veracity
Depending on the industry and organization, big data encompasses information from multiple internal and external sources such as transactions, social media, enterprise content, sensors and mobile devices. Companies can leverage data to adapt their products and services to better meet customer needs, optimize operations and infrastructure, and find new sources of revenue.
By 2015
4.4 MILLION IT JOBS
will be created globally to support big data, with 1.9 million in the United States
As of 2011, the global size of data in healthcare was estimated to be
150 EXABYTES
[161 BILLION GIGABYTES]
By 2014, it's anticipated there will be
420 MILLION WEARABLE, WIRELESS HEALTH MONITORS
4 BILLION+ HOURS OF VIDEO
are watched on YouTube each month
Variety
DIFFERENT FORMS OF DATA
30 BILLION PIECES OF CONTENT
are shared on Facebook every month
400 MILLION TWEETS
are sent per day by about 200 million monthly active users
1 IN 3 BUSINESS LEADERS
don't trust the information they use to make decisions
Poor data quality costs the US economy around
$3.1 TRILLION A YEAR
27% OF RESPONDENTS
in one survey were unsure of how much of their data was inaccurate
Veracity
UNCERTAINTY OF DATA
Sources: McKinsey Global Institute, Twitter, Cisco, Gartner, EMC, SAS, IBM, MEPTEC, QAS

Big Data 5V


The Five V's of Big Data
Scale of Data
This refers to the sheer volume of data being generated every second.
6 Billion People have cell phones
40 Zettabytes of data will be created by 2020 and increase of 300 times from 2005
Most companies in the U.S. have at least 100 Terabytes of data stored.
The New York Stock Exchange capture 1 TB of Trade Information
Analysis of Streaming Data
Denotes the speed at which data is emanating and changes are occurring between the diverse data sets.
By 2016 it is projected there will be 18.9 Billion network connections
Modern cars have close to 100 Sensors
Volume
Velocity
Veracity
Verity
Value
5V of Big Data
4 Billion+ hours of video are watched on You Tube each month
30 Billion pieces of content are shared on facebook every month
400 Million tweets are sent per day by about 200 million monthly active users
1 in 3 Business leaders don't trust the information they use to make decisions
Uncertainty Of Data
This refers to the discrepancies found in the data.
Poor data quality costa the US economy around $ 3.1 Trillion a year
Diffrent forms of data
As more and more data is being digitized.
Value Of Data
Having access to big data is all well and good but that's only useful if we can turn it into a value.

Acesso a dados em Big Data

- Sistemas de processamento de transações exigem escalabilidade muito alta
  - Muitas aplicações estão dispostas a sacrificar propriedades ACID e outros recursos do SGBD, se puderem obter escalabilidade muito alta
- Sistemas de processamento de queries que
  - Precisam de escalabilidade muito alta e
  - Necessidade de oferecer suporte a dados não relacionais

Sistemas de armazenamento em Big Data

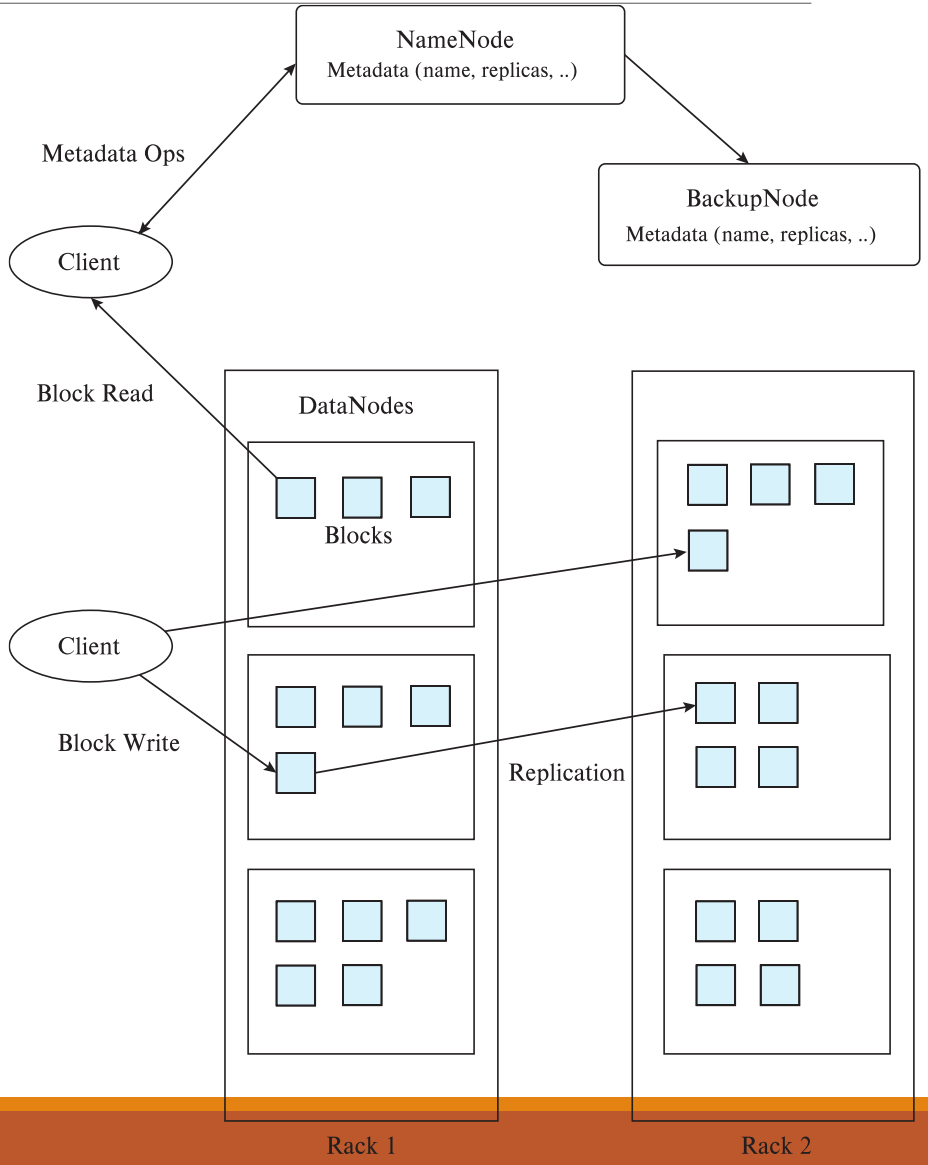
- Sistemas de gestão de ficheiros distribuídos
- Fragmentação (*Sharding*)
- Sistemas de armazenamento de chave-valor
- Bases de dados de grafos

Sistemas de gestão de ficheiros distribuídos

- Um sistema de gestão de ficheiros distribuído armazena dados numa grande coleção de máquinas, mas fornece uma única visão do sistema de ficheiros
- Sistema de gestão de ficheiros distribuídos altamente escaláveis para grandes aplicações com uso intensivo de dados.
  - Por exemplo, 10 mil nós, 100 milhões de ficheiros, 10 PB
- Fornece armazenamento redundante de grandes quantidades de dados em computadores de custo reduzido
  - Os ficheiros são replicados para lidar com falhas de hardware
  - Detecta falhas e recupera delas
- Exemplos:
  - Sistema de ficheiros do Google (GFS)
  - Sistema de ficheiros Hadoop (HDFS)

Arquitetura do sistema de ficheiros Hadoop

- Namespace único para todo o cluster
- Os ficheiros são divididos em blocos
  - Normalmente tamanho de bloco de 64 MB
  - Cada bloco replicado em vários DataNodes
- Cliente
  - Encontra a localização dos blocos do NameNode
  - Acede a dados diretamente do DataNode



Sistema de arquivos distribuídos Hadoop (HDFS)

- **NameNode**
  - Mapeia um nome de ficheiro para uma lista de IDs de bloco
  - Mapeia cada ID de bloco para DataNodes contendo uma réplica do bloco
- **DataNode** : mapeia um ID de bloco para um local físico no disco
- Coerência de dados
  - Modelo de acesso de gravação única e leitura múltipla
- Sistemas de ficheiros distribuídos são bons para milhões de ficheiros grandes
  - Mas tem custos muito altos e desempenho limitado com muitos (e.g., biliões) de tuplos menores

Fragmentação

- **Sharding** : particionar dados em várias bases de dados

  O particionamento é feito por ***atributos de particionamento*** (também conhecidos como ***chaves de particionamento*** ou ***shard keys,*** por exemplo, número de funcionário
  - Por exemplo, registos com valores-chave de 1 a 100.000 na BD1, registos com valores-chave de 100.001 a 200.000 na BD2, etc.

- A aplicação deve identificar a BD onde estão os registos pretendidos e enviar consultas/atualizações para essa BD

- Positivos: escala bem, fácil de implementar

- Desvantagens:
  - Não transparente: a aplicação tem que implementar o roteamento de consultas; podem haver consultas que abrangem várias BDs
  - Quando uma BD está sobrecarregada, mover parte de sua carga não é fácil
  - Probabilidade de falha maior com mais BDs

Sistemas de armazenamento de chave-valor

- Os sistemas de armazenamento de chave-valor armazenam grandes números (biliões ou até mais) de registos de tamanho pequeno (KB-MB)
- Os registos são **particionados** em várias máquinas e
- As consultas são encaminhadas pelo sistema para a máquina apropriada
- Os registos também são **replicados** em várias máquinas, para garantir a disponibilidade mesmo se uma máquina falhar
  - Os sistemas de armazenamento de chave-valor garantem que as atualizações são aplicadas a todas as réplicas, para garantir que os valores sejam **consistentes**

Sistemas de armazenamento de chave-valor

- Os sistemas de armazenamento de chave-valor podem armazenar
  - **bytes não interpretados** , com uma chave associada
    - Por exemplo, Amazon S3, Amazon Dynamo
  - **tabelas amplas** (podem ter um número de atributos arbitrário) com chave associada
    - Google BigTable , Apache Cassandra, Apache Hbase , Amazon DynamoDB
    - Permite que algumas operações (por exemplo, filtragem) sejam executadas no nó de armazenamento
  - JSON
    - MongoDB (BSON), CouchDB (documentos JSON)

Representação de Dados

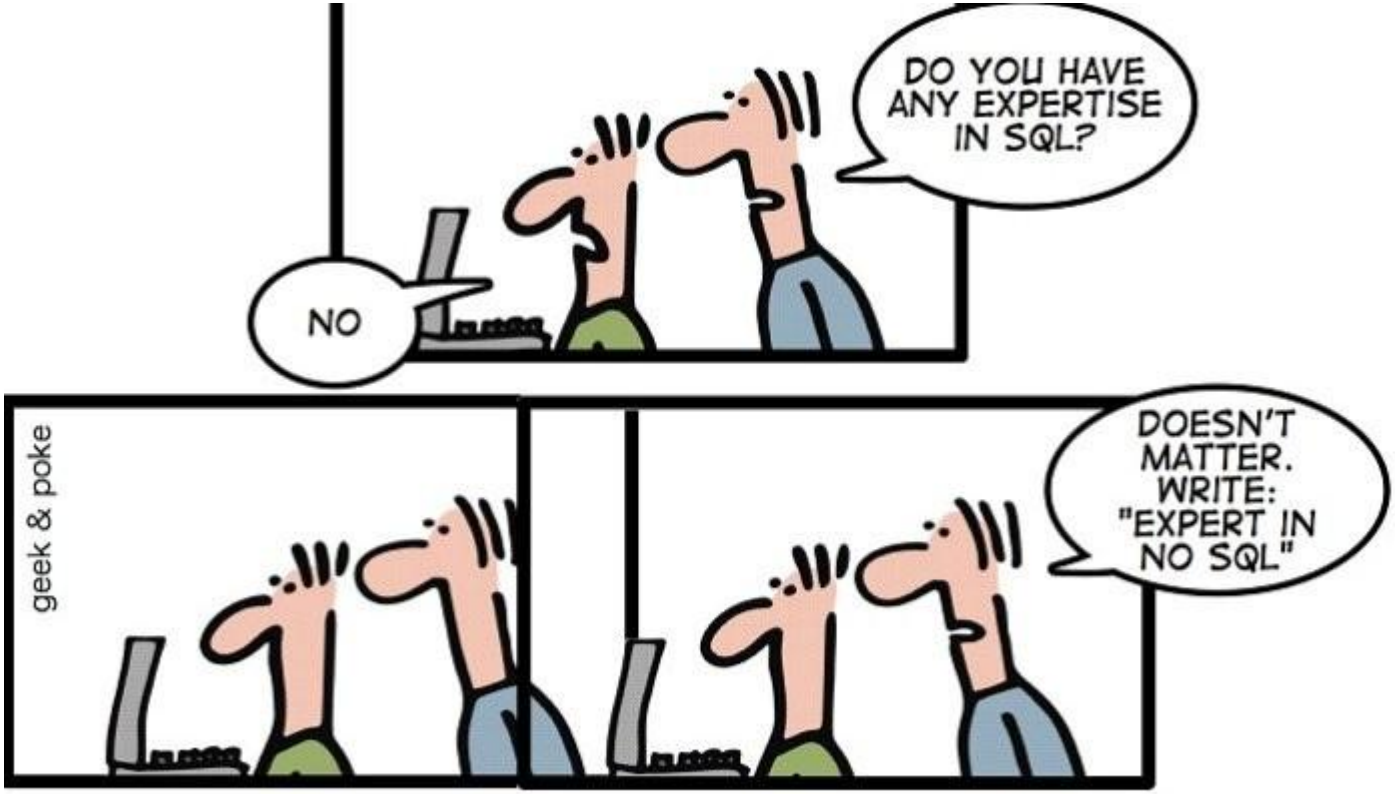
Um exemplo de um objeto JSON é:

```
{
   "ID": "22222",
   "name": {
        "firstname: "Albert",
        "lastname: "Einstein"
   },
   "deptname": "Physics",
   "children": [
        { "firstname": "Hans", "lastname": "Einstein" },
        { "firstname": "Eduard", "lastname": "Einstein" }
   ]
}
```

Sistemas de armazenamento de chave-valor

- Suportam as opeçãoes:
  - ***put*** (chave, valor): usado para armazenar valores com uma chave associada,
  - ***get*** (chave): recupera o valor armazenado associado à chave especificada
  - ***delete*** (chave): Remove a chave e seu valor associado
- Alguns sistemas também oferecem suporte ***a consultas de intervalo*** em valores da chave
- Os sistemas de armazenamento de chave-valor não são sistemas de gestão de bases de dados completos
  - Não têm suporte ou têm suporte muito limitado para transações
  - As aplicações têm que gerir o processamento de queries
- Não suportar os recursos acima torna mais fácil construir sistemas de armazenamento de dados escaláveis
  - Também conhecidos como sistemas **NoSQL**

NoSQL


DO YOU HAVE ANY EXPERTISE IN SQL?
NO
geek & poke
DOESN'T MATTER. WRITE: "EXPERT IN NO SQL"

NoSQL

NoSQL significa:

- No Relational
- No Relational Database Management System
- Not Only SQL

- Na prática NoSQL refere-se a todas as bases de dados e sistemas de armazenamento que não seguem os princípios do modelo relacional.

NoSQL – No ACID

- Bases de dados relacionais garantem as propriedades ACID das transações
- NoSQL
  - Não garante as propriedades ACID
- NoSQL BASE
  - **B**asically **A**vailable – a BD está disponível, mesmo que algumas partes do sistema falhem
  - **S**oft state – o estado da BD pode mudar ao longo do tempo, mesmo sem uma transação explícita
  - **E**ventual consistency – os dados podem ser inconsistentes temporariamente. Eventualmente, o sistema pode conseguir garantir a consistência em todos os nós